Theoretische Fundierung der t=1 Herleitung

Übersicht aller verwendeten Theorien, Methoden und Techniken mit Quellen

---

Inhaltsverzeichnis

1. Dynamic Programming & Bellman Equation
2. Backward Induction
3. Certainty Equivalence Principle
4. Quadratic Approximation (LQG Framework)
5. First Order Conditions (FOC)
6. Kettenregel (Chain Rule)
7. Cramer's Regel
8. Matrix Algebra Techniken
9. Linear Policy Functions
10. Envelope Theorem

---

1. Dynamic Programming & Bellman Equation {#1-dynamic-programming}

Wo verwendet?

In Schritt 3 bei der Formulierung der Zielfunktion:

$$V_1(y_1, d_1, b_1, \theta_1) = \min_{S_1, F_1} \left\{ \beta(w_y y_1^2 + w_d d_1^2 + w_b b_1^2) + \beta E_1[V_2^*] \right\}$$

Was ist Dynamic Programming?

Definition:

Dynamic Programming (DP) ist eine Methode zur Lösung sequentieller Entscheidungsprobleme, bei der ein komplexes Problem in einfachere Teilprobleme zerlegt wird.

Bellman's Principle of Optimality:

> "An optimal policy has the property that whatever the initial state and initial decision are, the remaining decisions must constitute an optimal policy with regard to the state resulting from the first decision."

Bellman Equation:

$$V_t(x_t) = \max_{u_t} \left\{ r_t(x_t, u_t) + \beta E_t[V_{t+1}(x_{t+1})] \right\}$$

wobei:

- $V_t(x_t)$: Value Function in Periode t
- x_t: Zustandsvektor
- u_t: Kontrollvektor
- r_t: Current period reward/cost
- β: Diskontfaktor
- $E_t[\cdot]$: Erwartungswert

Warum verwendet?

1. **Zerlegung:** Komplexes 3-Perioden-Problem wird in 2-Perioden-Problem reduziert
2. **Rekursion:** Lösung von t=2 wird in t=1 eingebettet
3. **Optimalität:** Garantiert global optimale Lösung
4. **Tractability:** Macht das Problem lösbar

Wie funktioniert es in unserem Fall?

Schritt 1: Löse t=2 (Terminal Period) → ergibt $V_2^*(y_2, d_2, b_2, \theta_2)$

Schritt 2: Verwende V_2^* als "Continuation Value" in t=1:

$$V_1 = \underbrace{\beta \cdot \text{Current Costs}}_{\text{Stage Cost}} + \underbrace{\beta E_1[V_2^*]}_{\text{Continuation Value}}$$

Schritt 3: Optimiere über (S_1, F_1) unter Berücksichtigung von V_2^*

Resultat: Die optimalen Policies in t=1 sind "forward-looking" - sie berücksichtigen automatisch alle zukünftigen Konsequenzen!

Quellen

Hauptreferenz:

- **Bellman, R. (1957).** *Dynamic Programming.* Princeton University Press.

Moderne Darstellung:

- **Stokey, N. L., Lucas, R. E., & Prescott, E. C. (1989).** *Recursive Methods in Economic Dynamics.* Harvard University Press.
  - Kapitel 3: "Dynamic Programming under Certainty"
  - Kapitel 9: "Dynamic Programming under Uncertainty"

Anwendung in Makroökonomie:

- **Ljungqvist, L., & Sargent, T. J. (2018).** *Recursive Macroeconomic Theory* (4th ed.). MIT Press.
  - Kapitel 3: "Dynamic Programming"
  - Besonders relevant: Section 3.1-3.3

Spezifisch für stochastische Optimierung:

- **Bertsekas, D. P. (2017).** *Dynamic Programming and Optimal Control* (Vol. 1, 4th ed.). Athena Scientific.
  - Kapitel 1: "The Dynamic Programming Algorithm"

---

2. Backward Induction {#2-backward-induction}

Wo verwendet?

Übergreifend: Die gesamte Lösungsstrategie basiert auf Backward Induction:

1. Zuerst t=2 lösen
2. Dann t=1 lösen (unter Verwendung von V_2*)
3. (Optional: t=0 lösen unter Verwendung von V_1*)

Was ist Backward Induction?

Definition:

Backward Induction ist die Methode, ein sequentielles Optimierungsproblem von der letzten Periode zur ersten zu lösen.

Algorithmus:

```
Gegeben: T Perioden

Schritt 1: Löse Period T (Terminal)
    → Ergibt V_T*(x_T)

Schritt 2: Löse Period T-1
    → Verwende V_T* als Continuation Value
    → Ergibt V_{T-1}*(x_{T-1}) und Policies u_{T-1}*

...

Schritt T: Löse Period 1
    → Verwende V_2* als Continuation Value
    → Ergibt V_1*(x_1) und Policies u_1*
```

Warum verwendet?

1. **Notwendigkeit:** Bei stochastischen Problemen mit Zustandsvariablen ist Forward Induction nicht möglich

2. **Terminal Conditions:** Wir kennen die Terminal Penalty → natürlicher Startpunkt
3. **Optimalität:** Garantiert durch Bellman's Principle
4. **Dimensionsreduktion:** Jede Periode wird separat gelöst

Wie funktioniert es in unserem Fall?

Period t=2 (Terminal Period):

$$V_2^* = \min_{S_2, F_2}\{\beta^2[\text{current costs}] + \beta^3[\text{terminal penalty}]\}$$

Resultat:

- Optimale Policies: $S_2^*(y_2, d_2, b_2, \theta_2)$, $F_2^*(y_2, d_2, b_2, \theta_2)$
- Value Function: $V_2^*(y_2, d_2, b_2, \theta_2) = \beta^2 \mathbf{x}_2^\top \mathbf{P}_2 \mathbf{x}_2$

Period t=1:

$$V_1^* = \min_{S_1, F_1}\{\beta[\text{current costs}] + \beta E_1[V_2^*]\}$$

Resultat:

- Optimale Policies: $S_1^*(y_1, d_1, b_1, \theta_1)$, $F_1^*(y_1, d_1, b_1, \theta_1)$
- Value Function: $V_1^*(y_1, d_1, b_1, \theta_1)$ (falls benötigt für t=0)

Kritisch: Die P_2-Matrix aus t=2 ist der "Informationstransfer" zwischen Perioden!

Quellen

Spieltheorie-Kontext (wo Backward Induction ursprünglich definiert wurde):

- **Selten, R. (1965).** "Spieltheoretische Behandlung eines Oligopolmodells mit Nachfrageträgheit." *Zeitschrift für die gesamte Staatswissenschaft*, 121, 301-324.

Ökonomische Dynamik:

- **Stokey et al. (1989).** *Recursive Methods in Economic Dynamics.*
  - Section 3.2: "Finite Horizon Problems"

Makroökonomische Anwendungen:

- **Ljungqvist & Sargent (2018).** *Recursive Macroeconomic Theory.*
  - Section 5.5: "Recursive formulation of dynamic programs"

Tutorial-Style:

- **Adda, J., & Cooper, R. (2003).** *Dynamic Economics: Quantitative Methods and Applications.* MIT Press.
  - Chapter 2: "Numerical Dynamic Programming"

3. Certainty Equivalence Principle {#3-certainty-equivalence}

Wo verwendet?

In Schritt 3.1 bei der Behandlung des Erwartungswerts:

$$E_1[V_2^*] = V_2^*(y_2, \bar{d}_2, b_2, \bar{\theta}_2) + \text{Konstante}$$

wobei:

- $\bar{\theta}_2 = E_1[\theta_2] = \rho_\theta \theta_1 - \phi_S S_1$
- $\bar{d}_2 = E_1[d_2] = \rho_d d_1 - \hat{\delta}_S S_1 + \delta_\theta \rho_\theta \theta_1$

Was ist Certainty Equivalence?

Definition:

Certainty Equivalence (CE) besagt, dass unter bestimmten Bedingungen die optimalen Policies in einem stochastischen Problem identisch sind mit denen eines deterministischen Problems, bei dem alle Zufallsvariablen durch ihre Erwartungswerte ersetzt werden.

Mathematisch:

Für ein stochastisches Problem:

$$\min_u E[L(x, u, \varepsilon)]$$

mit $x_{t+1} = f(x_t, u_t, \varepsilon_t)$ und ε_t stochastisch.

Unter CE gilt:

$$u^* = \arg\min_u L(\bar{x}, u, 0)$$

wobei $\bar{x} = E[x]$ und man $\varepsilon = 0$ setzt (bzw. $E[\varepsilon] = 0$).

Wann gilt Certainty Equivalence?

Notwendige Bedingungen (Simon, 1956; Theil, 1957):

1. **Quadratische Zielfunktion:** L ist quadratisch in Zuständen und Kontrollen
2. **Lineare Dynamik:** Zustandsgleichungen sind linear: $x_{t+1} = Ax_t + Bu_t + C\varepsilon_t$
3. **Additive Störungen:** Schocks treten additiv auf
4. **Erwartungsnutzen:** Minimierung von $E[L]$

Unser Fall erfüllt alle Bedingungen:

✅ **Quadratische Zielfunktion:** $V_2^* = \beta^2 \mathbf{x}_2^\top \mathbf{P}_2 \mathbf{x}_2$

✅ **Lineare Transitionsgleichungen:**

- $y_2 = \rho_y y_1 + \alpha_S S_1 - \alpha_F F_1$
- $\bar{d}_2 = \rho_d d_1 - \hat{\delta}_S S_1 + \delta_\theta \rho_\theta \theta_1$
- $b_2 = (1+r) b_1 + \kappa_F F_1 + \kappa_y y_1$

✅ **Additive Störung:** $\theta_2 = \rho_\theta \theta_1 - \phi_S S_1 + \varepsilon_2$

Warum verwendet?

1. **Vereinfachung:** Stochastisches Problem → deterministisches Problem
2. **Tractability:** Erwartungswert analytisch berechenbar
3. **Separation:** Optimierung und Unsicherheit können getrennt behandelt werden
4. **Optimalität:** Trotz Vereinfachung optimale Lösung!

Wie funktioniert es in unserem Fall?

Ausgangspunkt: Stochastisches Problem

$$E_1[V_2^*(\mathbf{x}_2)] = E_1[\beta^2 \mathbf{x}_2^\top \mathbf{P}_2 \mathbf{x}_2]$$

mit $\mathbf{x}_2 = \begin{pmatrix} y_2 \\ d_2 \\ b_2 \\ \theta_2 \end{pmatrix}$ und θ_2, d_2 stochastisch.

Schritt 1: Erwartungswert ausmultiplizieren

$$E_1[\mathbf{x}_2^\top \mathbf{P}_2 \mathbf{x}_2] = E_1[\mathbf{x}_2]^\top \mathbf{P}_2 E_1[\mathbf{x}_2] + \text{Var-Terms}$$

Schritt 2: Varianz-Terme beobachten

Die Varianz-Terme sind:

$$\text{Var}_1[d_2] = (\delta_\theta)^2 \text{Var}_1[\theta_2] = (\delta_\theta)^2 \sigma_2^2$$

$$\text{Var}_1[\theta_2] = \sigma_2^2$$

Diese sind **unabhängig von** (S_1, F_1)!

Schritt 3: Für Optimierung irrelevant

$$\frac{\partial}{\partial S_1}\text{Var-Terms} = 0$$

Daher können wir sie ignorieren!

Schritt 4: Certainty Equivalent Problem

$$E_1[V_2^*] \approx V_2^*(\bar{\mathbf{x}}_2) + \text{Konstante}$$

wobei $\bar{\mathbf{x}}_2 = E_1[\mathbf{x}_2]$

Resultat: Wir optimieren als ob die Zukunft deterministisch wäre, mit erwarteten Werten!

Praktische Implikation

Ohne CE:

- Müssten über alle möglichen Realisierungen von ε_2 integrieren
- Müssten für jede Realisation optimale Policies berechnen
- Exponentiell komplexes Problem

Mit CE:

- Setze einfach $\varepsilon_2 = 0$ (bzw. $E[\varepsilon_2] = 0$)
- Löse deterministisches Problem
- Ergibt dieselben optimalen Policies!

Magisch aber wahr: Die optimalen Policies sind dieselben!

Quellen

Ursprüngliche Arbeiten:

- **Simon, H. A. (1956).** "Dynamic programming under uncertainty with a quadratic criterion function." *Econometrica*, 24(1), 74-81.
  - **Erste formale Ableitung des CE Prinzips**
- **Theil, H. (1957).** "A note on certainty equivalence in dynamic planning." *Econometrica*, 25(2), 346-349.
  - **Erweiterung und Verallgemeinerung**

Moderne Darstellung:

- **Ljungqvist & Sargent (2018).** *Recursive Macroeconomic Theory.*
  - Chapter 5.6: "Certainty equivalence"
  - Sehr klare Darstellung mit Beweisen
- **Hansen, L. P., & Sargent, T. J. (2008).** *Robustness.* Princeton University Press.

- Chapter 2: "Certainty Equivalence"
- Diskutiert auch wann CE NICHT gilt

Stochastic Control Theorie:

- **Bertsekas, D. P. (2017).** *Dynamic Programming and Optimal Control* (Vol. 1).
  - Section 4.1: "Linear-Quadratic Problems"
  - Mathematisch rigoroser Beweis

Tutorial:

- **Sargent, T. J., & Stachurski, J. (2020).** "Dynamic Programming." In *QuantEcon Lectures*.
  - Online verfügbar: https://python.quantecon.org/lqcontrol.html
  - Sehr zugängliche Einführung mit Beispielen

---

4. Quadratic Approximation (LQG Framework) {#4-quadratic-approximation}

Wo verwendet?

Überall: Die gesamte Herleitung basiert auf quadratischen Zielfunktionen!

Explizit in:

- Value Function: $V_2^* = \beta^2 \mathbf{x}_2^\top \mathbf{P}_2 \mathbf{x}_2$
- Current costs: $w_y y_1^2 + w_d d_1^2 + w_b b_1^2$
- Zielfunktion: Quadratisch in (S_1, F_1) und Zuständen

Was ist das LQG Framework?

LQG = Linear-Quadratic-Gaussian

Ein Optimierungsframework mit:

1. **L (Linear):** Zustandsgleichungen sind linear $$x_{t+1} = A_t x_t + B_t u_t + C_t \varepsilon_t
2. **Q (Quadratic):** Zielfunktion ist quadratisch $$L = \sum_{t=0}^T (x_t^\top Q_t x_t + u_t^\top R_t u_t)
3. **G (Gaussian):** Störungen sind normalverteilt $$\varepsilon_t \sim N(0, \Sigma_t)

Warum quadratisch?

Theoretische Gründe:

1. **Taylor-Approximation:** Jede glatte Funktion kann lokal durch quadratische approximiert werden $$f(x) \approx f(x_0) + f'(x_0)(x-x_0) + \frac{1}{2}f''(x_0)(x-x_0)^2
2. **Risk-Aversion:** Quadratische costs reflektieren Risikoaversion
   - Abweichungen vom Ziel werden überproportional bestraft

- y^2 bestraft große Abweichungen mehr als kleine

3. **Analytische Lösbarkeit:** Quadratische Probleme haben geschlossene Lösungen
   - Keine numerische Optimierung nötig
   - Policies sind linear (siehe unten)

Praktische Gründe:

1. **Tractability:** Macht komplexe Probleme lösbar
2. **Certainty Equivalence:** Gilt nur für quadratische Probleme
3. **Tradition:** Standard in Makroökonomie seit 1950er Jahren

Wie funktioniert die quadratische Approximation?

In unserem COVID-19 Modell:

"Wahre" Zielfunktion (konzeptionell):

$$L = \sum_{t=1}^{3} \beta^t U(\text{GDP}_t, \text{Deaths}_t, \text{Debt}_t)$$

wobei $U(\cdot)$ eine allgemeine Nutzenfunktion ist.

Approximation um Steady State (z.B. Pre-COVID Niveau):

Angenommen $\text{GDP}^* = 100, \text{Deaths}^* = 0, \text{Debt}^* = 0$

Definiere Abweichungen:

- $y_t = 100 - \text{GDP}_t$ (Output gap)
- $d_t = \text{Deaths}_t - 0$ (excess deaths)
- $b_t = \text{Debt}_t - 0$ (excess debt)

Taylor-Expansion:

$$U(\text{GDP}, \text{Deaths}, \text{Debt}) \approx U^* + \underbrace{\text{linear terms}}_{\approx 0 \text{ at optimum}} - \frac{1}{2}[w_y y^2 + w_d d^2 + w_b b^2]$$

Die w-Gewichte sind die zweiten Ableitungen:

$$w_y = -\frac{\partial^2 U}{\partial \text{GDP}^2}, \quad w_d = -\frac{\partial^2 U}{\partial \text{Deaths}^2}, \quad \text{etc.}$$

Resultat: Quadratische "Loss Function" statt allgemeiner Utility!

Eigenschaften quadratischer Zielfunktionen

1. **Symmetrie:** y^2 bestraft positive und negative Abweichungen gleich
2. **Konvexität:** Garantiert eindeutiges Minimum
3. **Lineare FOCs:** Ableitungen sind linear → lineare Policies
4. **Geschlossene Lösung:** Via Riccati-Gleichungen

Grenzen der quadratischen Approximation

Wann ist sie gut?

- Kleine Abweichungen vom Steady State
- "Normale" Zeiten

Wann ist sie problematisch?

- Große Schocks (wie COVID-19!)
- Asymmetrien wichtig (z.B. Rezession schlimmer als Boom)
- Nichtlinearitäten relevant (z.B. Schuldenkrisen)

Für COVID-19: Die Schocks waren sehr groß → Approximation potenziell ungenau Aber: Alternative wäre numerische Optimierung → viel schwieriger Trade-off: Analytische Tractability vs. Genauigkeit

Quellen

LQG Control - Klassiker:

- **Kalman, R. E. (1960).** "A new approach to linear filtering and prediction problems." *Journal of Basic Engineering*, 82(1), 35-45.
  - **Grundlage des LQG Frameworks**
- **Athans, M. (1971).** "The role and use of the stochastic linear-quadratic-Gaussian problem in control system design." *IEEE Transactions on Automatic Control*, 16(6), 529-552.
  - **Umfassende Übersicht**

Ökonomische Anwendungen:

- **Chow, G. C. (1975).** *Analysis and Control of Dynamic Economic Systems.* Wiley.
  - Kapitel 3: "Optimal Control with Quadratic Objectives"
  - **Erste systematische Anwendung in Makroökonomie**
- **Kydland, F. E., & Prescott, E. C. (1982).** "Time to build and aggregate fluctuations." *Econometrica*, 50(6), 1345-1370.
  - Verwendet quadratische Approximation für RBC Modelle

Moderne Makro:

- **Woodford, M. (2003).** *Interest and Prices: Foundations of a Theory of Monetary Policy.* Princeton University Press.
  - Chapter 6: "Optimizing Models with Nominal Rigidities"
  - Verwendet quadratische Approximation für DSGE Modelle

Technische Details:

- **Ljungqvist & Sargent (2018).** *Recursive Macroeconomic Theory.*
  - Chapter 5: "Linear Quadratic Dynamic Programming"
  - Sehr detailliert, mit Beweisen

Tutorial mit Code:

- **QuantEcon:** "LQ Control Problems"
  - https://python.quantecon.org/lqcontrol.html
  - Mit Python-Implementierung

---

5. First Order Conditions (FOC) {#5-first-order-conditions}

Wo verwendet?

In Schritt 4.2 und 4.3:

$$\frac{\partial L}{\partial S_1} = 0 \quad \text{und} \quad \frac{\partial L}{\partial F_1} = 0$$

Was sind First Order Conditions?

Definition:

Die First Order Conditions sind die notwendigen Bedingungen für ein Optimum. Sie besagen, dass die Ableitung der Zielfunktion an einem Optimum gleich Null sein muss.

Mathematisch:

Für ein unbeschränktes Problem:

$$\min_x f(x)$$

Die FOC ist:

$$\frac{\partial f}{\partial x} = 0$$

Für mehrdimensionale Probleme:

$$\nabla f(x) = 0$$

wobei $\nabla f = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{pmatrix}$ der Gradient ist.

Warum FOCs verwenden?

Notwendige Bedingung:

An einem Minimum muss der Gradient verschwinden:

- Intuition: "Flacher Punkt" der Funktion
- Keine Richtung, in die man sich verbessern kann

Hinreichende Bedingung (zusätzlich):

Für ein Minimum muss zusätzlich die Hessian-Matrix positiv definit sein:

$$\mathbf{H} = \nabla^2 f(x) \succ 0$$

In unserem Fall:

✅ **FOCs sind notwendig:** $\nabla L = 0$

✅ **SOCs sind erfüllt:** $\mathbf{Q}_1 \succ 0$ (positiv definit)

→ FOCs charakterisieren das **eindeutige globale Minimum**

Wie funktionieren FOCs in unserem Fall?

Zielfunktion:

$$L(S_1, F_1) = \beta(w_y y_1^2 + w_d d_1^2 + w_b b_1^2) + \beta^3 E_1[V_2^*(y_2, \bar{d}_2, b_2, \bar{\theta}_2)]$$

FOC für S_1:

$$\frac{\partial L}{\partial S_1} = \underbrace{\frac{\partial[\text{current costs}]}{\partial S_1}}_{=0} + \beta^3 \frac{\partial E_1[V_2^*]}{\partial S_1} = 0$$

Der erste Term ist 0, weil current costs nicht von S_1 abhängen!

FOC für F_1:

$$\frac{\partial L}{\partial F_1} = 0 + \beta^3 \frac{\partial E_1[V_2^*]}{\partial F_1} = 0$$

Interpretation:

Die FOCs sagen: "Wähle (S_1, F_1) so, dass marginale Kosten = marginaler Nutzen"

- **Marginale Kosten:** Wie V_2^* steigt, wenn wir S_1 erhöhen
- **Marginaler Nutzen:** Wie V_2^* fällt durch positive Effekte von S_1

Am Optimum: Diese gleichen sich aus!

Quellen

Kalkül-Grundlagen:

- **Simon, C. P., & Blume, L. (1994).** *Mathematics for Economists.* W.W. Norton.
  - Chapter 17: "Unconstrained Optimization"
  - Chapter 18: "Constrained Optimization I"

Optimierung:

- **Sundaram, R. K. (1996).** *A First Course in Optimization Theory.* Cambridge University Press.
  - Chapter 2: "Optimization in $\mathbb{R}^n$"
  - Sehr klare Darstellung von FOCs und SOCs

Ökonomische Anwendung:

- **Mas-Colell, A., Whinston, M. D., & Green, J. R. (1995).** *Microeconomic Theory.* Oxford University Press.
  - Appendix M: "Calculus and Optimization"

Dynamische Optimierung:

- **Kamien, M. I., & Schwartz, N. L. (2012).** *Dynamic Optimization: The Calculus of Variations and Optimal Control in Economics and Management* (2nd ed.). Dover.
  - Chapter 2: "The Calculus of Variations: Foundations"

---

6. Kettenregel (Chain Rule) {#6-kettenregel}

Wo verwendet?

In Schritt 4.2 und 4.3 bei der Ableitung von $E_1[V_2^*]$:

$$\frac{\partial E_1[V_2^*]}{\partial S_1} = \sum_{j \in \{y,d,b,\theta\}} \frac{\partial V_2^*}{\partial x_{2,j}} \cdot \frac{\partial x_{2,j}}{\partial S_1}$$

Was ist die Kettenregel?

Definition:

Die Kettenregel (Chain Rule) beschreibt, wie man die Ableitung einer zusammengesetzten Funktion berechnet.

Eindimensional:

Für $y = f(g(x))$:

$$\frac{dy}{dx} = \frac{df}{dg} \cdot \frac{dg}{dx}$$

Mehrdimensional:

Für $z = f(y_1, \ldots, y_n)$ mit $y_i = g_i(x_1, \ldots, x_m)$:

$$\frac{\partial z}{\partial x_j} = \sum_{i=1}^{n} \frac{\partial f}{\partial y_i} \cdot \frac{\partial y_i}{\partial x_j}$$

Warum die Kettenregel?

Indirekte Effekte:

S_1 beeinflusst V_2^* nicht direkt, sondern nur indirekt über die Zustände in t=2!

Kausalkette:

$$S_1 \to \begin{cases} y_2 \\ \bar{d}_2 \\ b_2 \\ \bar{\theta}_2 \end{cases} \to V_2^*$$

Die Kettenregel formalisiert diese Kausalkette!

Wie funktioniert die Kettenregel in unserem Fall?

Schritt 1: Identifiziere die Abhängigkeiten

$$V_2^* = V_2^*(y_2(S_1, F_1), \bar{d}_2(S_1), b_2(F_1), \bar{\theta}_2(S_1))$$

Schritt 2: Wende Kettenregel an

$$\frac{\partial V_2^*}{\partial S_1} = \frac{\partial V_2^*}{\partial y_2} \cdot \frac{\partial y_2}{\partial S_1} + \frac{\partial V_2^*}{\partial \bar{d}_2} \cdot \frac{\partial \bar{d}_2}{\partial S_1} + \frac{\partial V_2^*}{\partial b_2} \cdot \frac{\partial b_2}{\partial S_1} + \frac{\partial V_2^*}{\partial \bar{\theta}_2} \cdot \frac{\partial \bar{\theta}_2}{\partial S_1}$$

Schritt 3: Berechne die Teile

*Teil A: Ableitungen von V_2 (aus der P_2-Matrix):**

$$\frac{\partial V_2^*}{\partial y_2} = 2\beta^2(P_{2,yy}y_2 + P_{2,yd}\bar{d}_2 + P_{2,yb}b_2 + P_{2,y\theta}\bar{\theta}_2)$$

$$\frac{\partial V_2^*}{\partial \bar{d}_2} = 2\beta^2(P_{2,yd}y_2 + P_{2,dd}\bar{d}_2 + P_{2,db}b_2 + P_{2,d\theta}\bar{\theta}_2)$$

usw.

Teil B: Ableitungen der Zustände (aus Transitionsgleichungen):

$$\frac{\partial y_2}{\partial S_1} = \alpha_S, \quad \frac{\partial \bar{d}_2}{\partial S_1} = -\hat{\delta}_S, \quad \frac{\partial b_2}{\partial S_1} = 0, \quad \frac{\partial \bar{\theta}_2}{\partial S_1} = -\phi_S$$

Schritt 4: Zusammensetzen

Einsetzen ergibt die FOC für S_1!

Interpretation

Jeder Term hat ökonomische Bedeutung:

$$\underbrace{\frac{\partial V_2^*}{\partial y_2}}_{\text{Wie teuer ist } y_2?} \cdot \underbrace{\frac{\partial y_2}{\partial S_1}}_{\text{Wie beeinflusst } S_1 \text{ das } y_2?} = \text{Totaler Effekt von } S_1 \text{ auf Kosten via } y_2$$

Die Kettenregel **aggregiert** alle indirekten Effekte!

Quellen

Grundlagen:

- **Stewart, J. (2015).** *Calculus: Early Transcendentals* (8th ed.). Cengage Learning.
  - Chapter 3.4: "The Chain Rule"
  - Chapter 14.5: "The Chain Rule" (multivariate)

Für Ökonomen:

- **Simon & Blume (1994).** *Mathematics for Economists.*
  - Chapter 14.3: "The Chain Rule"
  - Mit ökonomischen Anwendungen

In dynamischer Optimierung:

- **Chiang, A. C., & Wainwright, K. (2005).** *Fundamental Methods of Mathematical Economics* (4th ed.). McGraw-Hill.
  - Chapter 8: "Comparative-Static Analysis of General-Function Models"

- Zeigt Anwendung der Kettenregel in ökonomischen Modellen

---

7. Cramer's Regel {#7-cramers-regel}

Wo verwendet?

In Schritt 5.4 zur Lösung des 2×2 Systems:

$$\begin{pmatrix} Q_{1,SS} & Q_{1,SF} \\ Q_{1,SF} & Q_{1,FF} \end{pmatrix} \begin{pmatrix} S_1^* \\ F_1^* \end{pmatrix} = \begin{pmatrix} R_S^{(1)} \\ R_F^{(1)} \end{pmatrix}$$

Lösung:

$$S_1^* = \frac{1}{\Delta_1}[Q_{1,FF} \cdot R_S^{(1)} - Q_{1,SF} \cdot R_F^{(1)}]$$

$$F_1^* = \frac{1}{\Delta_1}[-Q_{1,SF} \cdot R_S^{(1)} + Q_{1,SS} \cdot R_F^{(1)}]$$

Was ist Cramer's Regel?

Definition:

Cramer's Regel ist eine explizite Formel zur Lösung linearer Gleichungssysteme mittels Determinanten.

Für ein n×n System:

$$\mathbf{A}\mathbf{x} = \mathbf{b}$$

Die Lösung ist:

$$x_i = \frac{\det(\mathbf{A}_i)}{\det(\mathbf{A})}$$

wobei $\mathbf{A}_i$ die Matrix ist, die entsteht, wenn man die i-te Spalte von $\mathbf{A}$ durch $\mathbf{b}$ ersetzt.

Warum Cramer's Regel?

Vorteile:

1. **Explizite Lösung:** Direkte Formel, keine Iteration
2. **Kompakt:** Für 2×2 sehr elegant
3. **Analytisch:** Kann symbolisch manipuliert werden
4. **Ökonomische Interpretation:** Jeder Term hat Bedeutung

Nachteile:

1. **Numerisch instabil:** Für große n schlecht
2. **Langsam:** O(n!) vs. O(n³) für Gauß-Elimination
3. **Nur für nicht-singuläre Systeme:** Erfordert $\det(\mathbf{A}) \neq 0$

In unserem Fall: 2×2 System → Cramer's Regel ist perfekt!

Wie funktioniert Cramer's Regel in unserem Fall?

Unser System:

$$\begin{pmatrix} Q_{1,SS} & Q_{1,SF} \\ Q_{1,SF} & Q_{1,FF} \end{pmatrix} \begin{pmatrix} S_1 \\ F_1 \end{pmatrix} = \begin{pmatrix} R_S \\ R_F \end{pmatrix}$$

Schritt 1: Determinante der Koeffizienten-Matrix

$$\Delta_1 = \det \begin{pmatrix} Q_{1,SS} & Q_{1,SF} \\ Q_{1,SF} & Q_{1,FF} \end{pmatrix} = Q_{1,SS} \cdot Q_{1,FF} - Q_{1,SF}^2$$

Schritt 2: Für S_1 - Ersetze erste Spalte mit rechter Seite

$$\mathbf{Q}_{1,S} = \begin{pmatrix} R_S & Q_{1,SF} \\ R_F & Q_{1,FF} \end{pmatrix}$$

$$\det(\mathbf{Q}_{1,S}) = R_S \cdot Q_{1,FF} - R_F \cdot Q_{1,SF}$$

$$S_1^* = \frac{\det(\mathbf{Q}_{1,S})}{\Delta_1} = \frac{Q_{1,FF} \cdot R_S - Q_{1,SF} \cdot R_F}{\Delta_1}$$

Schritt 3: Für F_1 - Ersetze zweite Spalte

$$\mathbf{Q}_{1,F} = \begin{pmatrix} Q_{1,SS} & R_S \\ Q_{1,SF} & R_F \end{pmatrix}$$

$$\det(\mathbf{Q}_{1,F}) = Q_{1,SS} \cdot R_F - Q_{1,SF} \cdot R_S$$

$$F_1^* = \frac{\det(\mathbf{Q}_{1,F})}{\Delta_1} = \frac{Q_{1,SS} \cdot R_F - Q_{1,SF} \cdot R_S}{\Delta_1}$$

Alternative: Matrix-Inversion

Äquivalent wäre:

$$\begin{pmatrix} S_1^* \\ F_1^* \end{pmatrix} = \mathbf{Q}_1^{-1} \begin{pmatrix} R_S \\ R_F \end{pmatrix}$$

mit:

$$\mathbf{Q}_1^{-1} = \frac{1}{\Delta_1} \begin{pmatrix} Q_{1,FF} & -Q_{1,SF} \\ -Q_{1,SF} & Q_{1,SS} \end{pmatrix}$$

Cramer's Regel ist äquivalent zur expliziten Inversion und Multiplikation!

Quellen

Lineare Algebra:

- **Strang, G. (2016).** *Introduction to Linear Algebra* (5th ed.). Wellesley-Cambridge Press.
  - Section 5.3: "Cramer's Rule, Inverses, and Volumes"
- **Anton, H., & Rorres, C. (2013).** *Elementary Linear Algebra: Applications Version* (11th ed.). Wiley.
  - Chapter 2.4: "Properties of Matrix Operations"
  - Chapter 2.5: "Elementary Matrices and a Method for Finding A^{-1}"

Für Ökonomen:

- **Simon & Blume (1994).** *Mathematics for Economists.*
  - Chapter 8.5: "Determinants"
  - Chapter 8.6: "Cramer's Rule"

Numerische Aspekte:

- **Golub, G. H., & Van Loan, C. F. (2013).** *Matrix Computations* (4th ed.). Johns Hopkins University Press.
  - Section 1.2: "Block Matrices and Algorithms"
  - Erklärt, warum Cramer nicht für große Systeme verwendet wird

---

8. Matrix Algebra Techniken {#8-matrix-algebra}

Wo verwendet?

Überall in der Herleitung:

1. **Matrix-Form der Value Function:** $V_2^* = \beta^2 \mathbf{x}_2^\top \mathbf{P}_2 \mathbf{x}_2$
2. **Zielfunktion:** $L = \mathbf{x}^\top \mathbf{W} \mathbf{x} + \mathbf{u}^\top \mathbf{Q} \mathbf{u} + 2\mathbf{u}^\top \mathbf{N} \mathbf{x}$

3. **FOC-System:** $\mathbf{Q}_1\mathbf{u}_1 = \mathbf{R}_1$

4. **Policy Functions:** $\mathbf{u}_1^* = \mathbf{A}_1\mathbf{x}_1$

Wichtige Matrix-Operationen

1. Ableitung quadratischer Formen

Regel:

$$\frac{\partial(\mathbf{x}^\top \mathbf{A}\mathbf{x})}{\partial \mathbf{x}} = 2\mathbf{A}\mathbf{x}$$

falls $\mathbf{A}$ symmetrisch ist.

Anwendung:

$$\frac{\partial V_2^*}{\partial \mathbf{x}_2} = \frac{\partial(\beta^2 \mathbf{x}_2^\top \mathbf{P}_2 \mathbf{x}_2)}{\partial \mathbf{x}_2} = 2\beta^2 \mathbf{P}_2 \mathbf{x}_2$$

2. Inverse einer 2×2 Matrix

Regel:

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix}^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

Anwendung:

$$\mathbf{Q}_1^{-1} = \frac{1}{\Delta_1} \begin{pmatrix} Q_{1,FF} & -Q_{1,SF} \\ -Q_{1,SF} & Q_{1,SS} \end{pmatrix}$$

3. Matrix-Multiplikation

Policy-Matrix:

$$\mathbf{A}_1 = \mathbf{Q}_1^{-1}\mathbf{N}_1$$

ist eine 2×4 Matrix, resultierend aus:

- $\mathbf{Q}_1^{-1}$: 2×2
- $\mathbf{N}_1$: 2×4

4. Kronecker-Produkt (implizit)

Bei der Expansion von $(\mathbf{A} + \mathbf{B})^2$ verwenden wir implizit:

$$(\mathbf{x}+\mathbf{y})^\top \mathbf{P}(\mathbf{x}+\mathbf{y}) = \mathbf{x}^\top \mathbf{P}\mathbf{x} + 2\mathbf{x}^\top \mathbf{P}\mathbf{y} + \mathbf{y}^\top \mathbf{P}\mathbf{y}$$

Warum Matrix-Notation?

Vorteile:

1. **Kompaktheit:** Eine Zeile statt vieler Terme
2. **Klarheit:** Struktur wird sichtbar
3. **Fehlerreduktion:** Weniger Indizes, weniger Fehler
4. **Computerfreundlich:** Direkt implementierbar
5. **Verallgemeinerung:** Leicht auf n-dimensionale Systeme erweiterbar

Beispiel:

Ohne Matrix: $$V_2 = P_{2,yy} y_2^2 + P_{2,dd} d_2^2 + \ldots + 2P_{2,yd} y_2 d_2 + \ldots$$ (10 Terme!)

Mit Matrix: $$V_2 = \mathbf{x}_2^\top \mathbf{P}_2 \mathbf{x}_2$$ (Eine Zeile!)

Quellen

Grundlagen:

- **Strang, G. (2016).** *Introduction to Linear Algebra.*
  - Comprehensive coverage of all matrix operations
- **Magnus, J. R., & Neudecker, H. (2019).** *Matrix Differential Calculus with Applications in Statistics and Econometrics* (3rd ed.). Wiley.
  - **Speziell für Ableitungen mit Matrizen**
  - Chapter 1: "Matrices"
  - Chapter 6: "Differentiation"

Für Ökonomen:

- **Simon & Blume (1994).** *Mathematics for Economists.*
  - Chapter 8: "Matrix Algebra"
  - Chapter 9: "Applications of Matrix Algebra"

Matrix Calculus:

- **Petersen, K. B., & Pedersen, M. S. (2012).** "The Matrix Cookbook." Technical University of Denmark.
  - **Freies Online-Referenzdokument**
  - Umfassende Sammlung von Matrix-Identitäten und Ableitungen
  - URL: https://www.math.uwaterloo.ca/~hwolkowi/matrixcookbook.pdf

9. Linear Policy Functions {#9-linear-policy-functions}

Wo verwendet?

Endergebnis in Schritt 5.7:

$$S_1^* = a_1^{S,y} y_1 + a_1^{S,d} d_1 + a_1^{S,b} b_1 + a_1^{S,\theta} \theta_1$$

$$F_1^* = a_1^{F,y} y_1 + a_1^{F,d} d_1 + a_1^{F,b} b_1 + a_1^{F,\theta} \theta_1$$

Warum sind die Policies linear?

Theorem (Linear-Quadratic Control):

Für ein LQ-Problem mit:

- **L (Linear):** $x_{t+1} = A_t x_t + B_t u_t + C_t \varepsilon_t$
- **Q (Quadratic):** $L = \sum_t (x_t^\top Q_t x_t + u_t^\top R_t u_t)$

Sind die optimalen Policies **immer linear** in den Zuständen:

$$u_t^* = -K_t x_t$$

wobei K_t eine Matrix von Feedback-Koeffizienten ist.

Warum ist das so?

Intuition:

1. **Quadratische Zielfunktion:** Ableitungen sind linear
2. **Lineare Transitionsgleichungen:** Keine Nichtlinearitäten eingeführt
3. **FOCs sind linear in (S, F):** Lineares Gleichungssystem
4. **Lösung eines linearen Systems:** Ist linear in der rechten Seite

Formal:

FOCs haben die Form:

$$\mathbf{Q}_1 \mathbf{u}_1 = \mathbf{N}_1 \mathbf{x}_1$$

Lösung:

$$\mathbf{u}_1^* = \mathbf{Q}_1^{-1} \mathbf{N}_1 \mathbf{x}_1 = \mathbf{A}_1 \mathbf{x}_1$$

Da $\mathbf{A}_1$ eine Konstanten-Matrix ist (hängt nicht von $\mathbf{x}_1$ ab), ist die Policy **linear**!

Eigenschaften linearer Policies

Vorteile:

1. **Einfachheit:** Leicht zu verstehen und implementieren
2. **Certainty Equivalence:** Gilt automatisch
3. **Time-Consistency:** Keine Anreize, von der Policy abzuweichen
4. **Komputierbar:** Geschlossene Form, keine numerische Optimierung

Nachteile:

1. **Keine Optionen:** Keine Berücksichtigung von Irreversibilitäten
2. **Keine Vorsicht:** Keine precautionary savings/behavior
3. **Symmetrie:** Reaktion auf positive und negative Schocks symmetrisch

In unserem Modell

Linear Policy bedeutet:

- 1% mehr Gesundheitsschaden → immer derselbe absolute Anstieg in Lockdown
- Unabhängig davon, ob Ausgangsniveau niedrig oder hoch ist

Realistisch? Fraglich bei großen Schocks wie COVID-19!

Alternative: Nichtlineare Policies

- Erfordern numerische Methoden (Value Function Iteration, Policy Function Iteration)
- Viel rechenintensiver
- Aber potenziell realistischer

Quellen

LQ Control Theory:

- **Anderson, B. D., & Moore, J. B. (2007).** *Optimal Control: Linear Quadratic Methods.* Dover.
  - Chapter 3: "Controllability and Observability"
  - Chapter 4: "Optimal Regulation: Full State Feedback"
  - **Beweist Linearität der optimalen Policies**

Ökonomische Anwendungen:

- **Hansen, L. P., & Sargent, T. J. (2008).** *Robustness.*
  - Chapter 2: "Recursive Methods"
  - Diskutiert lineare Policies im Kontext von Robustheit

- **Ljungqvist & Sargent (2018).** *Recursive Macroeconomic Theory.*
  - Chapter 5: "Linear Quadratic Dynamic Programming"
  - Section 5.5: "Linear Optimal Regulator"

Vergleich zu nichtlinearen Policies:

- **Judd, K. L. (1998).** *Numerical Methods in Economics.* MIT Press.
  - Chapter 12: "Approximation Methods"
  - Diskutiert wann lineare Approximation gut ist

---

10. Envelope Theorem {#10-envelope-theorem}

Wo verwendet?

Implizit bei der Herleitung von P_2: (aus t=2 Lösung)

Die Value Function V_1^* wird charakterisiert, ohne die optimalen Policies explizit einzusetzen.

Was ist das Envelope Theorem?

Definition:

Das Envelope Theorem besagt, dass die Ableitung einer Value Function nach einem Parameter gleich der partiellen Ableitung der Zielfunktion nach diesem Parameter ist, **evaluiert am Optimum**.

Mathematisch:

Für:

$$V(a) = \max_x f(x, a)$$

mit $x^*(a) = \arg\max_x f(x, a)$

Gilt:

$$\frac{dV}{da} = \frac{\partial f}{\partial a}\Big|_{x=x^*(a)}$$

Wichtig: Man muss NICHT $\frac{dx^*}{da}$ berechnen!

Warum ist das nützlich?

Vereinfachung:

Ohne Envelope Theorem:

$$\frac{dV}{da} = \frac{\partial f}{\partial a} + \frac{\partial f}{\partial x} \cdot \frac{dx^*}{da}$$

Mit Envelope Theorem:

$$\frac{dV}{da} = \frac{\partial f}{\partial a}$$

Der zweite Term verschwindet, weil $\frac{\partial f}{\partial x} = 0$ am Optimum (FOC)!

Wie wird es in unserem Modell verwendet?

Bei der Herleitung der P_2-Matrix:

Wir verwenden, dass:

$$\frac{\partial V_2^*}{\partial y_2} = \frac{\partial}{\partial y_2}\left[\min_{S_2,F_2}\{\ldots\}\right] = \frac{\partial L_2}{\partial y_2}\Big|_{S_2=S_2^*,F_2=F_2^*}$$

Wir müssen **nicht** $\frac{\partial S_2^*}{\partial y_2}$ und $\frac{\partial F_2^*}{\partial y_2}$ berechnen!

Bei der Kettenregel in t=1:

$$\frac{\partial E_1[V_2^*]}{\partial S_1} = \frac{\partial V_2^*}{\partial y_2} \cdot \frac{\partial y_2}{\partial S_1} + \ldots$$

Die Ableitung $\frac{\partial V_2^*}{\partial y_2}$ kommt aus dem Envelope Theorem!

Ökonomische Intuition

"Optimized-out" Effekte:

Am Optimum sind die Policies S_2^*, F_2^* bereits optimal gewählt. Kleine Änderungen in y_2 ändern S_2^*, F_2^*, aber dieser Effekt hat **keinen first-order Einfluss** auf den Wert, weil wir bereits am Optimum sind!

Nur der **direkte Effekt** von y_2 auf die Zielfunktion zählt.

Quellen

Original:

- **Samuelson, P. A. (1947).** *Foundations of Economic Analysis.* Harvard University Press.
  - Chapter 2: "Maximum Conditions"
  - **Erste formale Darstellung**

Moderne Darstellung:

- **Sundaram, R. K. (1996).** *A First Course in Optimization Theory.*
  - Section 4.6: "The Envelope Theorem"
  - Sehr klare Herleitung mit Beispielen

Für Ökonomen:

- **Mas-Colell et al. (1995).** *Microeconomic Theory.*
  - Section M.L: "The Envelope Theorem"
  - Mit ökonomischen Anwendungen

In dynamischer Optimierung:

- **Stokey et al. (1989).** *Recursive Methods in Economic Dynamics.*
  - Section 4.2: "The Envelope Condition"
  - Anwendung im Kontext von Dynamic Programming

Tutorial:

- **Carter, M. (2001).** *Foundations of Mathematical Economics.* MIT Press.
  - Chapter 8: "Constrained Optimization"
  - Section 8.5: "The Envelope Theorem"

Zusammenfassung: Theoretische Bausteine

Hierarchie der Methoden

```
Dynamic Programming (Bellman)
  ↓
Backward Induction
  ↓
LQG Framework (Quadratic + Linear + Gaussian)
  ↓
Certainty Equivalence
  ↓
First Order Conditions (Calculus)
  ↓
Kettenregel + Cramer's Regel
  ↓
Lineare Policy Functions
```

Kritische Annahmen für unsere Herleitung

Annahme	Wo gebraucht	Konsequenz wenn verletzt
Quadratische Zielfunktion	Überall	CE gilt nicht, keine geschlossene Lösung
Lineare Transitionsgleichungen	Schritt 3-5	Nichtlineare FOCs, numerische Lösung nötig
Additive Störungen	CE in Schritt 3	CE gilt nicht, Unsicherheit anders behandeln
Positive Definitheit von Q	Schritt 5	Keine eindeutige Lösung, SOCs verletzt

Annahme	Wo gebraucht	Konsequenz wenn verletzt
Bekannte P_2-Matrix	Schritt 3-5	Müssen t=2 zuerst lösen (Backward Induction)

Welche Methode ist am wichtigsten?

1. Certainty Equivalence (CE):

- Macht stochastisches Problem tractable
- Ohne CE: Müssten über alle Zufallspfade integrieren

2. Quadratic Approximation:

- Ermöglicht CE
- Ermöglicht lineare Policies
- Ermöglicht geschlossene Lösung

3. Dynamic Programming:

- Strukturiert das Problem
- Macht Backward Induction möglich
- Garantiert Optimalität

Literatur-Empfehlungen nach Niveau

Einführend:

- **Chiang & Wainwright (2005).** *Fundamental Methods of Mathematical Economics.*
  - Gut für Kalkül, Optimierung, Matrix Algebra

Intermediate:

- **Ljungqvist & Sargent (2018).** *Recursive Macroeconomic Theory.*
  - Umfassend für Dynamic Programming, LQG, CE

Fortgeschritten:

- **Stokey et al. (1989).** *Recursive Methods in Economic Dynamics.*
  - Rigoros, vollständige Beweise

Spezialisiert (LQG):

- **Anderson & Moore (2007).** *Optimal Control: Linear Quadratic Methods.*
  - Technisch tiefgehend

Online-Ressourcen:

- **QuantEcon Lectures:** https://quantecon.org
  - Moderne, code-basierte Tutorials

- Python und Julia Implementierungen
- Sehr zugänglich

Anhang: Quick Reference Guide

Formeln zum Nachschlagen

1. Bellman Equation:

$$V_t(x_t) = \max_{u_t}\{r_t(x_t, u_t) + \beta E_t[V_{t+1}(x_{t+1})]\}$$

2. Certainty Equivalence: $$E[V(x + \varepsilon)] \approx V(E[x]) + \text{const.}$$ (für quadratisches V und additives ε)

3. Kettenregel (multivariat):

$$\frac{\partial f(g(x))}{\partial x} = \frac{\partial f}{\partial g} \cdot \frac{\partial g}{\partial x}$$

4. Ableitung quadratischer Form: $$\frac{\partial (x^\top A x)}{\partial x} = 2Ax$$ (für symmetrisches A)

5. Inverse 2×2 Matrix:

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix}^{-1} = \frac{1}{ad - bc}\begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

6. Cramer's Regel (2×2):Für $Ax = b$:

$$x_1 = \frac{\det(A_1)}{\det(A)}, \quad x_2 = \frac{\det(A_2)}{\det(A)}$$

7. Envelope Theorem:

$$\frac{dV(a)}{da} = \frac{\partial f(x^*(a), a)}{\partial a}$$

Erstellt: 2025 Zweck: Vollständige theoretische Fundierung der t=1 Herleitung Zielgruppe: Fortgeschrittene Studierende und Forscher